

Estimació de la mètrica Expected Goals (xG) a partir de frames de vídeo mitjançant architectures de Deep Learning

Eloi Mercader, Enric Ortega, Nicolás García

Abstract—L'Expected Goals (xG) és una mètrica que estima la probabilitat que un xut acabi en gol i s'ha consolidat com una de les eines analítiques més rellevants del futbol modern. Els models actuals d'xG es basen majoritàriament en dades tabulars d'esdeveniments (posició del xut, part del cos, tipus de jugada) i ignoren la informació visual del moment del xut, on hi ha senyals fonamentals com la disposició dels defensors, la pressió sobre el xutador o la dinàmica de la jugada. En aquest projecte ens proposem estimar l'xG directament a partir dels frames de vídeo del xut, formulant el problema com una classificació binària (gol / no gol) i interpretant la probabilitat de la classe positiva com a xG. Treballarem sobre el dataset SoccerNet, del qual disposem de vídeos complets de partits i d'un fitxer JSON amb tots els esdeveniments etiquetats al segon.

Plantegem dues aproximacions complementàries de visió per computador: (i) un pipeline purament basat en imatge, on extraurem el frame de cada xut i entrenarem architectures CNN, CNN+LSTM i CNN+Attention sobre seqüències de frames; (ii) una aproximació alternativa en què, mitjançant homografia, projectarem les posicions dels jugadors detectats al pla 2D del camp i construirem un model tabular amb feature engineering sobre aquestes coordenades. La comparació entre ambdues vies ens permetrà discutir el valor afegit que aporta la informació visual respecte als models tabulars clàssics.

Keywords—Expected Goals, Deep Learning, CNN, LSTM, Attention, YOLO, homografia, anàlisi esportiva, SoccerNet.

1 INTRODUCCIÓ

L'anàlisi quantitativa del futbol ha viscut una transformació profunda durant l'última dècada. La progressiva disponibilitat de dades d'esdeveniments i de tracking ha permès passar d'un model d'anàlisi qualitativa, basat en l'observació de l'expert, a un paradigma data-driven on cada acció del partit s'avalua amb mètriques objectives. Entre totes aquestes mètriques, l'Expected Goals (xG) ha esdevingut una de les més populars: estima la probabilitat que un xut acabi en gol en funció de les característiques de l'acció, i serveix per quantificar el rendiment ofensiu d'un equip o d'un jugador més enllà del simple recompte de gols.

Tradicionalment els models d'xG s'entrenen sobre dades tabulars d'esdeveniments —coordenades del xut, part del cos amb què

s'efectua, tipus de jugada prèvia, etc.— i fan servir tècniques de regressió logística o gradient boosting. Aquesta aproximació, tot i ser efectiva, pateix una limitació important: descarta la riquesa visual del moment del xut. La posició relativa dels defensors, la línia del porter, l'angle de visió del xutador o la pressió defensiva són factors que un model tabular només pot capturar de forma molt aproximada (si és que es modelen explícitament), però que un humà observant el frame interpreta immediatament.

La hipòtesi de partida d'aquest projecte és que els frames de vídeo del moment del xut contenen informació suficient per estimar la probabilitat de gol amb un nivell de qualitat comparable —o complementari— al dels models tabulars tradicionals. Per validar aquesta hipòtesi proposem dues aproximacions paral·leles. La primera és un pipeline de visió end-to-end: a partir del frame (o seqüència de frames) del xut, una xarxa neuronal profunda aprèn directament a discriminar entre gol i no gol, i la probabilitat de la classe positiva s'interpreta com a xG. La segona és una aproximació alternativa: mitjançant tècniques d'homografia projectarem les deteccions dels jugadors al pla 2D del camp, construirem un conjunt de features tabulars i ajustarem un model clàssic. Comparar ambdues vies ens permetrà entendre quin tipus de senyal —visual o estructural— és més informatiu per a la tasca.

1.1 Objectius

Els objectius inicials del projecte —que poden refinar-se durant el desenvolupament— són els següents:

- Construir un dataset de frames de xuts a porteria, etiquetats com a gol o no gol, a partir dels vídeos i les anotacions d'esdeveniments del dataset SoccerNet.
- Resoldre la imprecisió temporal entre les anotacions (resolució al segon) i el vídeo (10 fps), filtrant els frames vàlids per al problema.
- Implementar i entrenar diverses architectures de Deep Learning per a la classificació binària gol / no gol: una CNN sobre el frame del xut, i extensions amb LSTM i Attention sobre la seqüència de frames previs.
- Plantejar una aproximació alternativa basada en homografia + model tabular i comparar-la amb el pipeline de visió per quantificar l'aportació de la informació visual.
- Avaluar tots els models amb mètriques de classificació estàndard i amb una validació qualitativa sobre exemples concrets, comparant els xG predits amb la intuïció futbolística.

2 ESTAT DE L'ART

2.1 Models clàssics d'Expected Goals

Els primers models d'xG documentats a la literatura analítica esportiva són models de regressió logística sobre features tabulars senzilles: distància a porteria, angle de visió del marc i

tipus de xut. Aquesta família de models, popularitzada per plataformes com Opta, StatsBomb o Wyscout, ha estat àmpliament adoptada per la seva interpretabilitat. Treballs més recents [1] han escalat aquests models cap a Gradient Boosting Trees (XGBoost, LightGBM) afegint variables contextuais com la pressió, el tempo de la jugada o la posició dels defensors propers, sempre però en format tabular. La principal limitació és que la qualitat del model depèn críticament de la riquesa de les dades d'esdeveniments disponibles, i en escenaris de dades més escasses el model perd resolució.

2.2 Visió per computador en l'esport

L'aplicació de tècniques de visió per computador al futbol ha crescut amb la disponibilitat de datasets amb vídeo i anotacions sincronitzades. SoccerNet [2] s'ha consolidat com el benchmark principal del sector, oferint més de 500 partits complets amb anotacions d'esdeveniments al segon i tasques canòniques com action spotting, replay grounding o detecció de càmera. En el context de la detecció i seguiment d'objectes, els detectors de la família YOLO [3] dominen pel seu balanç entre precisió i velocitat, i s'utilitzen rutinàriament per detectar jugadors i pilota.

2.3 Aprenentatge profund per a classificació de seqüències

El nucli tècnic del nostre pipeline visual rau en arquitectures de Deep Learning per a classificació d'imatges i seqüències. Les xarxes convolucionals (CNN) [4] són l'estàndard per extreure representacions de cada frame. Per modelar la dinàmica temporal entre frames consecutius, les xarxes recurrents tipus LSTM són una opció clàssica, però els mecanismes d'atenció i, més generalment, les arquitectures Transformer [5] han demostrat avantatges importants en tasques de seqüència gràcies a la seva capacitat de capturar dependències a llarg abast i de paral·lelitzar l'entrenament. En aquest projecte explorarem aquestes dues vies (CNN+LSTM i CNN+Attention) per a la modelització de la jugada immediatament anterior al xut.

2.4 Estimació d'xG amb informació visual

La línia de treballs que estima xG directament des de la imatge és encara incipient. Algunes aproximacions recents combinen detecció de jugadors amb pose estimation per inferir features estructurals del xutador i el seu entorn, alimentant després un model tabular. La nostra proposta s'inspira en aquesta línia però explora dues direccions paral·leles: una via end-to-end on és la pròpia xarxa qui aprèn la representació rellevant a partir del píxel, i una via tabular obtinguda per homografia que substitueix la representació visual per coordenades sobre el camp.

3 PROPOSTA

La nostra proposta s'estructura al voltant d'un pipeline modular que va des de la matèria primera (vídeo + anotacions de SoccerNet) fins a l'estimació final de l'xG. A continuació en detalllem les etapes i, en paral·lel, descrivim l'aproximació alternativa basada en homografia que utilitzarem per a la comparació final.

3.1 Dades

Treballarem sobre el dataset SoccerNet [2], que proporciona, per a cada partit, dos vídeos a 10 fps que cobreixen la primera i la segona part i un fitxer JSON amb les anotacions de tots els esdeveniments rellevants (xut a porta, xut fora, gol, falta, córner, etc.), cadascun etiquetat amb el minut i el segon en què té lloc. A més, els JSON inclouen informació sobre el jugador que executa l'acció i sobre els jugadors implicats com a defensors, fet que farem servir per identificar el xutador i el seu entorn.

D'aquest dataset filtrarem els esdeveniments del tipus xut a porta, xut fora i gol, que constituïran les mostres positives i negatives del problema de classificació binària. Mitjançant un script extreurem el frame corresponent a l'instant indicat de cada xut a partir del vídeo de la part del partit pertinent.

3.2 Flux de procés del sistema de visió

El pipeline principal del sistema de visió consta de les següents etapes:

- Extracció de frames: per cada esdeveniment de xut filtrat al JSON, recuperem el frame del vídeo corresponent al segon anotat i, addicionalment, els frames anteriors per disposar d'una seqüència temporal que capturi la dinàmica prèvia al xut.
- Filtratge de frames vàlids: com que la resolució temporal de les anotacions és al segon i el vídeo va a 10 fps, no tots els frames extrets corresponen efectivament a l'instant del xut. Caldrà, per tant, dissenyar un mecanisme de selecció dels frames adequats com a tasca prèvia a l'entrenament; explorarem diferents estratègies basades en detecció d'objectes i en agrupament de representacions visuals.
- Etiquetatge: cada xut queda etiquetat amb la seva classe (1 = gol, 0 = no gol) a partir del JSON original.
- Entrenament: entrenarem successivament les arquitectures descrites a continuació, totes formulades com a classificació binària amb sortida sigmoide; la probabilitat de la classe positiva s'interpretarà com a xG.

3.3 Arquitectures proposades

Plantegem tres arquitectures de complexitat creixent. La primera és una CNN entrenada des de zero sobre el frame de l'instant del xut, que servirà de baseline visual. La segona afegeix una capa LSTM per modelar la dinàmica temporal entre el frame del xut i els frames immediatament anteriors, capturant així el moviment

del joc previ a l'acció. La tercera substitueix la LSTM per un mecanisme de self-attention sobre la seqüència de frames, inspirat en l'encoder de Transformer [5], i ens permetrà comparar els avantatges de l'atenció respecte a la recurrència.

3.4 Aproximació alternativa: homografia + model tabular

En paral·lel al pipeline visual plantejem una segona aproximació que aprofita tècniques clàssiques de visió per computador per generar una representació estructural del joc. La idea és estimar, per a cada frame del xut, la matriu d'homografia que projecta el pla de la imatge al pla 2D del camp; per fer-ho, detectarem línies i punts característics del camp (línies de banda, àrea, cercle central) i resoldrem la correspondència amb un model conegut del terreny de joc.

Un cop tenim la homografia, projectarem les bounding boxes dels jugadors detectats per YOLO [3] al pla del camp, obtenint coordenades 2D normalitzades per a cadascun. Sobre aquestes coordenades aplicarem feature engineering per construir un vector tabular: distància del xutador a la porteria, angle de visió del marc, nombre de defensors entre el xutador i la porteria, distància al defensor més proper, distància del porter a la línia de gol, etc.

Amb aquest dataset tabular ajustarem un model clàssic d'xG (regressió logística i, per comparació, XGBoost) i el contrastarem amb el pipeline visual end-to-end. Aquesta comparació és l'aspecte central de la nostra proposta des del punt de vista de l'assignatura: ens permetrà discutir si la informació visual aporta senyal addicional un cop ja disposem de la representació estructural del camp, o si la representació tabular obtinguda per homografia ja captura la major part de la informació rellevant.

3.5 Avaluació

Avaluarem tots els models amb mètriques estàndard de classificació binària sobre un conjunt de test independent: accuracy, precision, recall, F1 i AUC-ROC. Donat que el dataset està desbalancejat —els gols són una minoria respecte als xuts— prestarem especial atenció a l'AUC i al F1 sobre la classe positiva. Complementarem aquesta avaluació quantitativa amb una validació qualitativa sobre exemples concrets: visualitzarem el frame del xut amb el valor d'xG predit superposat i contrastarem la coherència del model amb la intuïció futbolística sobre la dificultat de cada acció.

BIBLIOGRAFIA

[1] T. Decroos, L. Bransen, J. Van Haaren, and J. Davis, "Actions speak louder than goals: Valuing player actions in soccer," in Proc. 25th ACM SIGKDD Int. Conf. Knowledge Discovery & Data Mining, 2019, pp. 1851–1861.

[2] S. Giancola, M. Amine, T. Dghaily, and B. Ghanem, "SoccerNet: A scalable dataset for action spotting in soccer videos," in Proc. IEEE CVPR Workshops (CVPRW), 2018, pp. 1711–1721.

[3] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in Proc. IEEE CVPR, 2016, pp. 779–788.

[4] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE CVPR, 2016, pp. 770–778.

[5] A. Vaswani et al., "Attention is all you need," in Advances in Neural Information Processing Systems (NeurIPS), 2017, pp. 5998–6008.